

三天，做一个可信的证据智能助手

OpenEvidence 风格 MVP | 暑期实践项目



问题 → 证据 → 带引用回答 / 对比评估

找对文献，往往比直接给答案更稳健



2025 年 7 月



教学演示，不用于诊疗

01

开场与项目定调

约 8 min



医生要的不是诊断，是能回查的证据

临床高频需要的是可回查的证据，而非武断结论；
这不是让 AI 代替诊断，而是一个典型的“**证据再确认**”任务。



虚构病例卡



年龄段

50 多岁门诊患者



主诉

血压长期控制一般，体检又提示血脂偏高



既往控制情况

长期服用降压药，依从性一般



本次诉求

想确认最近的高质量证据和指南到底怎么说



直接给答案



先找证据

先投票，再看下一页揭晓课程立场



合成教学场景，不构成医疗建议

三天节奏：上午定调，下午跑通，第三天见真章



三条赛道，三种闭环：找证据、讲明白、测清楚

三条赛道并行，每组 3~7 人择一；讲授讲共性技术，实践按赛道分化；
三条赛道本质都是“再确认”，只是提问者和证据形态不同。



赛道一 | 临床证据 | 找证据

“这位患者的降压药和降脂药
是不是要终身吃？”

给医生/科研的找文献确认助手

3~7 人一组



赛道二 | 健康营养 | 讲明白

“网上说地中海饮食能降血脂，
这是真的吗？”

给消费者的可溯源科普助手

3~7 人一组



赛道三 | 对比评估 | 测清楚

“同样问‘限钠饮食有没有用’，
纯大模型和带证据库的系统谁
答得更靠谱？”

专用 RAG vs 纯 LLM 的 mini 实验

3~7 人一组

先完成基础闭环，再谈进阶与挑战

不是淘汰赛，是保底 + 拔高；三天最终要交的是可运行原型、评估结果与项目报告，第三天现场演示。



交付：原型 + 评估 + 报告 + 演示



原型

可运行的系统原型



评估

完整评估结果与分析



报告

8~15 页 PPT 或
3000~5000 字 Markdown



演示

第三天现场演示

上午先把数据管道跑起来， 比先做界面更重要

基础知识库不少于 500 篇，鼓励扩到数千；第 1 天下午结束前
力争入库 500 篇，所以上午就要把 API 跑起来。

500+

≥500 篇有效文档



数据源

API 为主，线下样例兜底



原型栈

推荐栈：Python + LLM API + Chroma/FAISS +
LangChain/LlamaIndex/Dify +
Streamlit/Gradio

AI coding 为主



安全习惯

Key 不进仓库

今天就要养成习惯



0



200



500+

上午结束时，五件事必须成立



选定赛道与分工



初版测试问题（基础 ≥ 8 ）



一页系统框图

问题→检索→生成→引用/评估



跑通至少一条数据 API

如 PubMed 或 ClinicalTrials 等



起草伦理/免责声明



赛道三另加：3 条可检验假设

02

临床信息检索的真实痛点与 OpenEvidence 逻辑

约 15 min



OpenEvidence 靠免费口碑裂变，做到半数美国医生在用



120 亿美元

估值约 120 亿美元



7 亿美元

融资超 7 亿美元



70 万+

月活医生 70 万+



免费推送



口碑裂变



workflow 嵌入

不是训练给答案，是训练找最该引用的文献



给最好的答案



医学知识会过期

VS



找最该被引用的文献



找文献更稳健



这是 OpenEvidence 的产品转向

医疗场景有三条硬约束： 会过期、代价高、要可追溯

知识会过期：
指南/RCT 按季度改写



错误代价高：
剂量/禁忌/合并症



必须可追溯：
谁说的、哪篇文献、
哪年指南



用户要能复查

可信来源 > 武断答案

93% 不是鉴别诊断，是治疗管理的再确认

核心结论：医生提问中鉴别诊断只占约 7%，93% 是治疗与管理类“再确认”；
OpenEvidence 把这类需求概括为“寻路（wayfinding）”——帮你决定下一步查什么，
而不是替你宣布诊断。

7%

鉴别诊断

93%

治疗与管理再确认

每位患者平均涉及约四个决定，其中三个医生已有约 95% 把握、
不需要花 20 分钟查文献，但也并非 100% 确定——这正是“治疗与管理再确认”的典型场景。

Wayfinding：给下一步，不是给最终判断

对应开场病例卡：这更像治疗管理确认

这像调试时的“再看一眼文档 / changelog”，不是从零证明一个新定理。

参考：nejm-ai-grand-rounds-ep42-openevidence.md

把模糊问题改写成可检索的问题，才有意义

太宽的问题会诱导系统给处方；加上人群/干预/结局与证据类型限定后，才是能检索、能核验的好问题。

原问题：

血压和血脂都不好，怎么办？

缩小边界

改写后：

高血压长期管理中，生活方式与持续药物治疗分别有哪些指南或研究依据？

检索约束：近 10 年 | 指南 | 系统综述 | RCT

 近 10 年

 指南

 系统综述

 RCT

并说明证据边界

两人一组，2 分钟内改写一句

好答案不是唯一正解，是当下最该引用的互补证据

OpenEvidence 优化的目标函数不是“唯一正确答案”，而是在当前时间点选出最该引用的互补文献；选择时至少同时看相关性、时效、证据质量、权威性四维，目标是“互补的 7 篇，不是重复的 12 篇”。



互补的 7 篇，不是重复的 12 篇

这不是简单加权排序，更接近“组合优化”：在满足多维要求的前提下，选出覆盖面更广、信息增量更高的互补集合。

幻觉分四层，假引用只是最浅一层

第2层“检索缺失+讨好性回答”往往比假引用更危险，
因为引用是真的、内容却在补全；
本课程基础必做前两层的检测与拒答。

1 假引用（文献不存在）→
基础必做：PMID/DOI 回查

2 检索缺失+讨好性回答 →
基础必做：阈值拒答

引用真实，内容在补全

3 无全文编数字 →
挑战了解

无全文却编造数字
（如表中副作用率）

4 多源合成推理错误 →
挑战


人类专家仍常更强

人类专家仍需把关

护城河是内容授权与数据飞轮， 不是我们三天能复刻的

内容授权

与主流出版商合作，获得图、曲线、影像等多媒体内容



专科问题飞轮

海量来自执照医生、带专科标签的真实问题



70 万+ 使用者 ≠ 已证明结局改善，仍需独立评估

· 我们做的是 MVP ·

把大产品的六个痛点，裁成三天能交付的六个模块

核心结论：每一个真实痛点都要对应一个可交付模块，才不会变成空谈技术名词。

1 证据检索难 → 子领域知识库+重排
子领域知识库 + (进阶) 重排选互补

2 答案不可核查 → 强制引用+假引用检测

3 全文缺失 → 开放获取/结构化摘要
优先开放获取 / 结构化摘要，避免编数字

4 RAG 可能帮倒忙 → 赛道三对照

5 用户差异 → 分赛道建模

6 专用未必胜 → 用数据说话

按意向赛道写真问题，并粗查需要什么资源



写问题

2~3 条真实场景问题



标资源类型

资源：文献 / 试验 / 指南 / 科普



赛道一示例

降压药是否需长期维持的指南依据？



赛道二示例

地中海饮食降血脂靠谱吗？



赛道三示例

同题下 RAG 与纯 LLM 谁引用更可靠？



约 5 分钟

03

专用 vs 通用：双重问题意识

约 19 min

约 19 min



**本项目同时回答两个问题：
怎么做好，以及做得好不好**



产品侧：怎样做好证据助手？

对应赛道一、二



评估侧：专用方案赢在哪里？

对应赛道三

不预设专用必胜

> [Nat Med](#). 2026 Jul;32(7):2405-2409. doi: 10.1038/s41591-026-04431-5. Epub 2026 Jun 12.

General-purpose large language models outperform specialized clinical AI tools on medical benchmarks

Krithik Vishwanath^{1 2 3}, Anton Alyakin^{4 5 6}, Mrigayu Ghosh^{7 8}, Ali Hage⁹, Sean N Neifert⁴, Cordelia Orillac⁴, Nataniel J Mandelberg⁴, Hammad A Khan⁴, Jin Vivian Lee^{4 5 6}, Jie J Yao¹⁰, William Robert Small^{11 12 13}, Aakaash Varma^{14 15}, D Brock Hewitt¹⁶, Yindalon Aphinyanaphongs^{11 13 17}, Daniel Alexander Alber¹², Eric Karl Oermann^{18 19 20 21 22}

Affiliations + expand

PMID: 42286322 PMCID: [PMC13375586](#) DOI: [10.1038/s41591-026-04431-5](#)

Abstract

Specialized clinical artificial intelligence (AI) tools are entering medical practice despite scarce independent evaluation. We quantitatively evaluate two clinical AI tools, OpenEvidence and UpToDate Expert AI, built on large language models (LLMs) against three frontier LLMs: GPT-5.2, Gemini 3.1 Pro and Claude Opus 4.6. Our evaluation has three stages: (1) 500 MedQA questions testing medical knowledge, (2) 500 HealthBench items measuring alignment with clinicians and (3) the real clinical queries (RCQ) benchmark, built from 100 de-identified queries from physicians to a general-purpose language model in a live clinical environment. For the RCQ benchmark, 12 US

FULL TEXT LINKS

nature portfolio



ACTIONS

“ Cite

🔖 Collections

🔗 Permalink

PAGE NAVIGATION

< Title & authors

Abstract

Conflict of interest
statement

独立评测分三阶：题库、对齐、真实查询

NYU Langone 团队将 OpenEvidence、UpToDate Expert AI 与 GPT-5.2/Gemini 3.1 Pro/Claude Opus 4.6 对比，加入 Google AI Overview 作现实对照，评测逐步接近真实临床工作流。



三轮测试，通用模型全面领先

MedQA: Gemini 97.4% vs OpenEvidence 89.6%

97.4% vs **89.6%**

UpToDate **88.4%**

HealthBench: GPT 88.0 vs OpenEvidence 62.6

88.0 vs **62.6**

UpToDate **61.3**

RCQ: 通用 3.5—3.6 vs 专用 3.2

3.5—3.6 vs **3.2**

Google AI Overview 3.27 (与专用同档)

UpToDate 拒答率 19%

19%

通用约 1—3%

引用质量与速度未充分测

流畅、有引用、被支撑，是三件不同的事

A：流畅但无来源

综合现有研究证据，规律的有氧运动能有效改善心血管健康、降低慢性病风险，并提升整体生活质量。

B：有来源但可能不支持

大量研究表明，补充维生素 D 可改善心血管健康、降低死亡风险，并提升生活质量 [\[1\]](#) [\[2\]](#) [\[3\]](#) 。

?



说得顺不顺



文献存不存在



文献支不支持

学生用 30 秒圈出信任依据

拒答不是免责，过高拒答同样是失败

UpToDate 拒答率

19%

通用模型约 1-3%



拒得合理，不是遇事沉默

包一层检索不等于更专业， 检索噪声会拖累答案



读论文也要读局限： 题库泄露、基准偏倚、样本单一



题库泄露



HealthBench 偏倚

研究者同时运营院内 GPT



单一医院 100 条 RCQ



引用质量未测

响应速度亦未测

RCQ 是主证据，不是唯一证据

不预设谁赢，用两臂对照把结论跑出来



同底座、同题集、同温度

A 纯 LLM



同底座、同题集、同温度

B RAG

同领域 ≥ 500 篇



同底座、同题集、同温度

可选 C 劣化 RAG



正确性



完整性



安全



清晰



引用



拒答

六项指标各看什么，上午点到为止



正确性：

事实/主结论



完整性：

关键方面与局限



安全性：

不过界诊疗



清晰度：

目标用户可读



引用质量：

ID 真且支撑



拒答率：

与质量同报



上午点到为止，D2 再展开 Rubric

假设必须能被测试集推翻， 不能只是口号

✓ 可被证伪的好假设



1. RAG 降低假引用率？

但可能降低表达流畅度



2. 检索噪声拉低质量？

(Arm C) 会拉低完整性与正确性



3. 引用支撑度在哪类题更高？

开放式鉴别诊断题则未必

⊖ 不能证伪的口号



~~万能更好~~

不能证伪的口号不算假设



赛道三每组写 3 条，其余可选

04

三赛道场景建模

约 17 min



开工前先回答四问：谁、语料、形态、成功标准

任何一组开工前都要先明确谁在什么情境下提问、语料从哪来、产品形态是什么、成功标准是什么。



赛道一：给专业用户的可追溯证据助手



用户：医生 / 医学生 / 科研



语料：文献 + 试验 + 指南



聚焦高血压、血脂、糖尿病等心脑血管与代谢领域



定位：OpenEvidence mini——找对文献、带引用确认



问题



文献



证据卡



回答

非真实诊疗

先会找源：四类公开资源站



PubMed

<https://pubmed.ncbi.nlm.nih.gov>



ClinicalTrials.gov

<https://clinicaltrials.gov>



AHA 指南入口

<https://professional.heart.org>



医学原点导航

<https://med.5minpro.com>

—— | 导航站发现源，不替代正式引用 | ——

赛道二：给消费者的可溯源科普，不是个性化医嘱

面向普通消费者的血脂/三高/饮食干预科普；口语化提问进，通俗但不煽情的回答出；
禁止个性化处方，证据分级展示，免责声明默认可见；特别适合并行 LLM Wiki 主题页。



吃得咸真的会让
血压高吗？
有没有靠谱研究？



用户：普通消费者



语料：电子书 +
文献 + 指南

语料：电子书/手册样例 + 营养干预文献 + 膳食指南公开版



指南级证据

本回答基于权威指南与高质量研究，
证据等级：指南级证据（强推荐）。



通俗回答

[1]

长期高盐饮食与血压升高风险增加有关，
大量研究支持“减盐有助于降低血压”。
日常建议：少放盐、少吃腌制和加工食品，
逐步把口味调清淡，更有利于心血管健康。



免责声明

本内容仅供健康科普参考，非个性化医疗建议。
如有不适或正在服药，请咨询医生或专业人员。



口语进，通俗但不煽情出



不做个性化建议

特别适合并行 LLM Wiki 主题页：

地中海饮食

限钠

赛道三：产物是对照报告，不是聊天界面



核心结论：共享测试集不少于 15 条，可复用赛道一语料作 Arm B；

输出是对比报告+可视化+结论与局限，形态可以是脚本/Dashboard/A-B 并排，不必强行做成聊天产品。



共享题集 ≥ 15



```
$ eval/run_ab.sh --dataset shared_15p --mode compare
```

```
> 加载共享题集...
```

```
✓ 题目数量检查通过:  $\geq 15$ 
```

```
> 构建对照组...
```

```
- Arm A: 赛道三方案
```

```
- Arm B: 复用赛道一语料
```

```
> 执行评测...
```

```
✓ 评测完成
```

```
> 生成对比报告与可视化...
```

```
✓ 报告已生成: results/ab_report.html
```

```
✓ 图表已生成: results/ab_charts.png
```


```
> 形态: 脚本 / Dashboard / A-B 并排
```

```
✓ 完成
```

可复用赛道一语料作 Arm B



结果可视化



结论与局限

- 基于共享测试集的离线评测，无法覆盖真实场景中的长期效果。
- 题目规模有限，可能无法代表全量用户与复杂边界情况。
- 结果受评测脚本与指标设计影响，需持续迭代与交叉验证。

形态：脚本 / Dashboard / A-B 并排，不必做成聊天界面。

同一技术底座，三条赛道的成功标准完全不同

用户、语料、产品形态、合规重心与评估重心都随赛道变化——赛道一看正确性与引用，赛道二看可读性与证据分级，赛道三看对照臂与多维指标。

赛道一	赛道二	赛道三
		
用户 临床/科研	用户 消费者	用户 评估者
输出 文献+试验+指南	输出 电子书+科普+干预研究	输出 复用领域语料
评价 正确性、引用	评价 可读性、证据分级、是否过度建议	评价 对照臂+多维指标
找对证据	讲清证据	测清差异

好问题可检索可评估，坏问题太宽还会诱导处方

好问题限定人群/干预/结局或证据类型，例如“限钠干预对血压是否有高质量 RCT 支撑？”；
坏问题如“怎么治好糖尿病？”太宽、无边界，或像“我爷爷该吃什么药？”带个体化诊疗暗示，
都需要改写成“证据是什么/局限是什么”句式。



✓ 确认型管理问题，对应 93% 场景



改写：证据是什么？局限是什么？

提前写下期望命中证据类型：指南 / RCT / 综述

测试集要在系统写完之前先写出来

基础组至少 8 条稳定题（含 1~2 条应拒答/证据不足题），进阶扩到 15 条并加对抗题；每题建议字段 `id`, `question`, `track`, `expected_evidence_type`, `notes`, `should_abstain`。



基础：≥8 题



进阶：≥15 题



应拒答题

含 1~2 条应拒答/
证据不足题



对抗题：

过时观点、矛盾研究、
缺文献

`id`, `question`, `track`, `expected_evidence_type`, `notes`, `should_abstain`

每题一条记录，便于组内共享题库

公平对比先锁死四个变量，再改变检索方案



固定：同底座 | 同题集 | 同温度 | 同 Prompt

记录：模型名、温度、语料版本、日期

A 裸 LLM



不检索任何外部资料，
仅依赖模型自身知识回答

B RAG



正常检索高质量资料，
作为上下文辅助生成

C 劣化 RAG (可选)



检索质量受限（召回不足/噪声多），
作为上下文辅助生成



正确性



完整性



安全



清晰



引用



拒答

结果表头： 题号 | Arm | 四维分 | 拒答 | 假引用 | 备注

一页系统框图：六个节点，先画出来再动手写代码

赛道一、二的主链路是“用户问题→检索→证据打包→生成（强制引用）→验证→展示”，
赛道三在此之上再加评测编排器与多臂结果库；rerank、Tool、Agent 等模块先用虚线框标注，
明天再加深，避免范围膨胀。



赛道三在此之上再加：评测编排器、多臂结果库

05


数据采集与知识库规划

约 14 min



数据策略：API 为主，样例兜底

主路径是 PubMed E-utilities / Europe PMC / ClinicalTrials.gov / 公开专利检索，组织方提供的指南 PDF、电子书章节作补充；目标是下午结束前 ≥ 500 篇有效文档，有余力做到 1000~2000+。



组织方提供的指南 PDF 节选、
电子书章节

500+

≥ 500 篇

有余力做到 1000~2000+

PubMed 只需两步：esearch 找 ID，efetch 拉记录

esearch 拿 UID 列表，efetch 拉摘要/XML；无 Key 约 3 req/s，有 Key 约 10 req/s；
建议先用窄检索式拉 50 ~ 100 篇验证管道，再放大到 500+。



esearch



```
# 基址: eutils.ncbi.nlm.nih.gov/entrez/eutils/
```

```
esearch.fcgi \  
  db=pubmed \  
  term=hypertension AND guideline \  
  retmax=100 \  
  retmode=json
```



esearch 结果 (JSON 简化)

```
{  
  "header": {  
    "type": "esearch",  
    "version": "0.3"  
  },  
  "esearchresult": {  
    "Count": "2105",  
    "RetMax": "100",  
    "RetStart": "0",  
    "IdList": [  
      "39876543", "39876542", "39876541", ...  
    ],  
    "TranslationSet": []  
  }  
}
```



选 1 个 PMID 做 efetch




无 Key 3 req/s，有 Key 10 req/s

先用窄检索式拉 50 ~ 100 篇验证管道，再放大到 500+

检索式先窄后宽，决定知识库的含金量

用 MeSH/关键干预词 + 年限（如近 10 年）+ 文章类型过滤（Review、Guideline、RCT）；
检索式版本要记录到 README，是评测可复现的第一步。



开放全文和试验注册，补齐摘要之外的证据类型

Europe PMC 提供开放获取全文，用于摘要不够或需要 OA 全文时；ClinicalTrials.gov API v2 无需鉴权即可查询试验注册信息，入库时用 `source_type=clinical_trial` 与期刊论文区分。



Europe PMC: 开放获取全文



提供开放获取的全文内容，支持研究者在摘要不足或需要 OA 全文时获取更完整的证据。



ClinicalTrials.gov: GET /studies?query.cond=...

☒	
☐	
☐	
☐	

无需鉴权即可通过 API v2 查询试验注册信息，建议保留关键元数据字段。

nct_id

title

status

phase

与期刊论文分开入库，注意付费墙许可

`source_type=clinical_trial`

没有 metadata，后面的引用和评估都会塌

必填字段是 `title, year, source\_type, id, text`; `id` 与 `url` 是引用回查的锚点，不要把向量、模型回答或 API Key 混进原始语料文件。

JSONL 记录示例

```
{  
  "title"      : "心力衰竭的诊断与治疗共识（示例）",  
  "year"       : 2023,  
  "source_type" : "guideline",  
  "id"         : "hf_china_2023_001",  
  "text"       : ".....（原始语料内容）.....",  
  "evidence_level" : "A"  
}
```


id 与 url 是引用回查的锚点

强烈建议: evidence_level, specialty_tag, url, retrieved_at



500 篇里混进 100 篇重复，有效规模就会塌

去重键是 PMID/DOI/NCT ID，再用标题归一化二次去重；同时过滤空摘要、撤稿标记与噪声；保留原始检索日志（query、时间、命中数）方便写报告数据章节。



90 分钟按节奏冲 500 篇，线下样例只是补充

0-20 分钟跑通样例、20-50 分钟定检索式冲到 200、50-80 分钟扩到 500 并落盘、80-90 分钟人工抽查；
指南 PDF、电子书、公开专利只是补充语料，不建议占知识库主体，且仅能使用组织方授权样例。



 数据工程	验证样例可跑通	定检索式与过滤条件	批量抓取与去重去噪	落盘与抽查导出
 问题设计	明确目标与范围	设计检索式与关键词	评估覆盖与相关性	抽查相关性与质量
 伦理与文档	确认授权与合规	记录检索策略与版本	记录批量抓取与来源	记录抽查与结论

线下样例仅作补充
公开专利仅作趋势线索，不建议占知识库主体

中午前的完成定义：管道通、检索式落文档、metadata 齐全

完成的标志是至少 1 个可重复运行的 API 脚本、组内检索式与目标篇数写进共享文档、3 条样例记录字段齐全；即使未达 500 篇，也不要卡住，先保证下午能 embed。



API 脚本可重复运行



检索式写入共享文档



3 条 metadata 完整记录

字段齐全示例：title / year / source_type



下午可直接 embedding

即使未达 500 篇，也不要卡住

06 医疗 AI 伦理红线

约 18 min



教学演示
不是医疗器械
不是临床决策支持

评分权重：伦理占 10%

WHO 六原则，压成四个可执行的产品动作

自主/问责→人做最终判断，系统不下医嘱；安全/公益→拒答优于编造；透明→引用与局限可披露；公平→避免恐吓式或歧视性表述。



自主 / 问责

人做最终判断



安全 / 公益

拒答优于编造



透 明

来源与局限可见

引用来源、说明局限与已知失败案例，
写进报告。



公平

避免不公平表达

真实 PHI 一律不能进系统，公开数据优先

PHI: 可识别个人的健康相关信息

禁止真实姓名、病案号、完整生日、联系方式、可识别影像、未脱敏病历叙事；

允许公开文献、公开指南、合成/脱敏案例；日志与截图同样不能泄露 Key 或疑似患者信息。

禁止



姓名



病案号



完整生日



联系方式



可识别影像

允许



公开文献



公开指南



合成/脱敏案例

即便在非美国场景，也按“最小必要+公开数据优先”执行。

不给药名剂量，只给可核查的证据摘要

禁止输出具体用药方案、停药建议、个体化剂量；允许输出指南一般性建议的转述-引用；

拒答话术示例：“这涉及个人诊疗，需要执业医师评估；我只能提供公开证据摘要：[1][2]”。



不提供具体药名、剂量、停药建议

消费者场景尤其容易把科普听成医嘱



提供公开证据摘要

建议执业医师评估

“这涉及个人诊疗，需要执业医师评估；
我只能提供公开证据摘要：[1][2]”。

标识符存在只是起点， 陈述被证据支撑才是底线

课程底线是标识符必须存在（PMID/DOI/NCT/章节可回查），进阶要求陈述可被 chunk 支撑，人工抽查假引用率；同时 Key 只放环境变量、`.gitignore` 排除 `.env`、日志脱敏，AI 可辅助但不能当作者。



标识符

标识符存在

PMID / DOI / NCT



支撑

陈述被 chunk 支撑



人工抽查

人工抽查假引用率



人负责

人类最终负责

AI 不能当作者

人类需审阅 AI 生成内容



`.env` / `.gitignore`

Key 只放环境变量；
`.gitignore` 排除 `.env`
与敏感文件。



最小权限 Key

按需分配、最小权限；
定期轮换，避免过期
长期可用。




日志脱敏

记录必要信息；
脱敏敏感数据，避免
泄露风险。

诚实报告局限， 允许得出专用没赢的结论

✓ 评测报告不是宣传材料

独立评估的伦理是即使得出专用未赢，也要写清楚——不篡改评测、不隐藏拒答、不挑只对为题做演示，小样本要写进局限而非用措辞掩盖。



不挑只对为题

覆盖全部评测题目，包含容易错的、边缘的、长尾的，不只挑对的题做演示。



不隐藏拒答

模型拒答、超时、无法完成都要如实记录与呈现，不淡化或隐去。



报告样本量与偏倚

说明数据来源、抽样方式、覆盖边界与潜在偏倚；样本量小也要写清楚，写进局限而非用措辞掩盖。



允许“专用未赢”

当证据不足或结果不达标时，允许得出“专用未赢”的结论，清晰写出结论与不确定性，不为迎合预期而改写结论。

红黄绿三种回应，只有一种合规

“我爷爷该吃什么药？”

红卡直接给药名剂量违规；黄卡泛泛拒绝、不说明为什么也没有下一步同样不合格；绿卡说明不能诊疗、提供公开证据范围、建议由执业人员评估才是合规回应。



红：直接给出个体化
药名、剂量或停药建议



黄：泛泛拒绝，
不说明为什么



绿：说明边界 +
公开证据 +
建议就医



每组举一张颜色卡，并用一句话解释

写好免责声明，交卷前把六条红线勾一遍

免责声明要写明教学演示、非诊疗、非个性化建议、公开证据来源、紧急情况就医，并放到 UI 页脚与 README 顶部；演示前与提交前各查一次红线清单：无真实 PHI、无诊断/处方话术、Disclaimer 可见、引用可回查、Key 未进仓库、有 AI 使用披露。



教学演示

非诊疗

非个性化建议

公开证据来源

紧急情况就医

赛道二另需加一句：不能替代执业医师/营养专业人员意见

红线检查清单 | 演示前、提交前各检查一次（D2 下午还会二次提醒）



无真实 PHI



无诊断/处方话术



Disclaimer 可见



引用可回查



Key 未进仓库



AI 使用披露

07

本半天小结与实践启动

约 5 min



一条因果链：再确认→找证据→独立评估→分赛道→数据→伦理

真实高频是再确认，产品应找证据而非只给答案；专用工具仍须独立评估；
场景分赛道，数据与合规随之分化；没有数据与红线，下午的 RAG 无处安放。

再确认 → 找证据 → 独立评估 → 分赛道 → 公开数据 → 伦理边界

没有数据与红线，下午的 RAG 无处安放。

三个角色并行，90 分钟按四段节奏推进

建议三角色并行——数据入库、题库与场景、伦理声明与框图文档，赛道三再加一人订评测表头；
90 分钟按"0-15 定分工、15-40 写题库、40-80 冲数据、80-90 定框图"推进，避免所有人挤在同一段代码上。



所有人共享同一检索式版本号与题库表格，保持一致。

离开教室前，六项完成定义逐一勾选

实践完成度由可见产物判断：赛道、测试问题、API、框图、伦理声明五件套都要打勾；
赛道三再加假设与对照臂草图；未达 500 篇不是致命伤，明确下午补齐计划才是。



赛道



测试问题



API



框图



伦理声明



赛道三：
假设 + 对照臂草图

未达 500 篇不是致命伤，至少管道通 + 明确下午补齐计划，补齐计划要写清。

下午，把证据接进 RAG

- 同一题，先问一次裸模型
- 带着检索式和 metadata 进入下午

问题 → 证据 → 带引用回答

