

# 把资料接成一条不撒谎的证据链

D1 下午 | RAG、检索优化、幻觉防御与 LLM Wiki

从“有没有资料”转向“能不能可回查地回答”——  
检索、幻觉防御与知识维护共同撑起这条证据链。

问题 → 证据 → 带引用回答 / 证据不足 → 拒答



# 01

## 从「拉到数据」到「可回查回答」

从有没有资料，到能不能可回查地回答



**下午验收看两件事：一条带引用 QA，一次纯 LLM 对照**



**验收 = 1 条带引用 QA + 1 次纯 LLM 对照**

# 上午的产出，是下午系统的输入

赛道

回答语言

赛道一专业证据表述，赛道二通俗科普不越界，赛道三保存多臂回答

测试题

检索是否有明确目标

API

能否过滤/引用/回查

id/title/year/source\_type/text/url

伦理声明

Prompt 的拒答边界

不能最后才贴在 UI 页脚

先用最小 RAG 把资料变成能引用的上下文

# 能聊天、能检索、能回答且可回查，是三件不同的事



**裸 LLM:**

流畅，来源不可核验

缺的关键环节：缺外部证据



**只做搜索:**

一堆标题，无综合引用

缺的关键环节：缺综合与引用绑定



**最小 RAG:**

基于片段回答，逐句可回查

缺的关键环节：还需检验检索质量



检索噪声、错误引用、强行补全仍会发生

# 先跑通最小闭环，再谈进阶与挑战

核心结论：基础必做入库、向量检索、Top-K 打包、强制引用、低置信度拒答；

进阶和挑战都是加分项、不能压垮基础组；赛道三的基础要求是固定配置并保存 Arm A/B 结果。



## 基础必做

入库、向量检索、  
Top-K打包、强制引用、  
低置信度拒答

先跑通，不求全



## 进阶建议

BM25+向量混合、  
metadata过滤、  
MMR、rerank、Wiki



## 挑战选做

查询改写、  
多轮检索、  
自动化评估



赛道三基础：固定配置 + 保存 Arm A/B

# 系统里的 `[1]` 最终要指向 `id` 和 `url`，不是模型现造的文献名

## JSONL 记录 (单行示例)

|             |                                                                                                   |
|-------------|---------------------------------------------------------------------------------------------------|
| id=pmid:... | pmid:34567890                                                                                     |
| title       | Effects of Exercise on Cardiovascular Health                                                      |
| year        | 2023                                                                                              |
| abstract    | This study investigates the impact of ...                                                         |
| url         | <a href="https://pubmed.ncbi.nlm.nih.gov/34567890/">https://pubmed.ncbi.nlm.nih.gov/34567890/</a> |
| source_type | journal_article                                                                                   |

字段齐全即可进 pipeline, 不必完美

[1]

[1] 指向 id 和 url,  
不是临时生成的文献名



备用：无 API 数据时，取样例 10 条先跑通

# 02

## RAG 基础：检索质量决定回答上限

RAG 只给模型看证据的机会，不保证用对



# 纯 LLM 有三类硬伤：过期、编造、看不见依据



知识有截止日期



事实可能编造



用户看不到依据

这是 RAG 要解决的起点

# RAG 接上可更新的外部记忆，但只保证“有机会看到”

注意：RAG 不等于上传文件后让模型随便总结；关键在于检索到相关证据并将其纳入生成过程。



更新索引  $\neq$  更新模型



有机会看到证据  $\neq$  正确使用证据

# 六个工程动作，串成一条能被回查的链



任一步不透明，可回查就断掉

工具建议：Python + Chroma/FAISS，先不引入过多框架

# PubMed 整段留，指南按章节切，不能一刀切

⚠ 切太小：没有上下文

⚠ 切太大：噪声上升，引用定位不了

PubMed：标题+摘要+metadata 整体作单元



🔒 作为一个不可再分的整体单元

先不逐句碎切

指南/PDF：按章节/推荐语句切分，不拆散表格



# 每个 chunk 必须能定位到“它支撑了哪句话”

## chunk 必须继承

- source\_id
- 标题
- 年份
- URL

能定位到“哪个 chunk 支撑哪句话”

进阶：300-500 token, 10%-20% overlap

基础组不在此处调参

# Top-K 不是越大越安全，要为可核查的证据包服务

起步建议检索 Top-5，生成时仅使用筛选后的 3~5 段；若 Top-5 全部边缘相关，模型更容易把它们拼成一个貌似完整的错误答案；K 首先是可演示性和可审查性参数。



## Top-3

证据是否不足，  
可能漏掉关键依据？

多出来的候选  
是证据，还是干扰？

## Top-10

是否包含较多边缘或重复信息，  
影响判断与生成质量？  
多出的 7 篇



**核心结论：**起步建议检索 Top-5，生成时仅使用筛选后的 3~5 段；若 Top-5 全部边缘相关，模型更容易把它们拼成一个貌似完整的错误答案；K 首先是可演示性和可审查性参数。

# 入库—检索只是候选证据，还不是“回答”

```
# 1) 写入：来自上午 JSONL 的原始记录 (id 不可更改)
collection.upsert(
  ids=[record["id"]],
  documents=[record["text"]],
  metadatas=[{
    "title": record["title"],
    "year": record["year"],
    "url": record["url"],
    "source_type": record["source_type"]
  }]
)

# 2) 检索：只取候选证据（此时还不是回答）
collection.query(
  query_texts=[query],
  n_results=5
)
```

id 来自上午 JSONL，不允许模型重新命名

演示重点：数据结构，不是安装速度

## 候选证据 (top-5)

还不是回答

1

标题占位：心力衰竭患者出院后远程随访的有效性研究

来源：期刊文章 | 年份：2021 | 类型：journal article

摘要片段占位：本研究探讨了远程随访对心力衰竭患者再入院率的影响，结果显示远程管理可显著降低再入院风险，并改善患者自我管理能力……

2

标题占位：慢性阻塞性肺疾病患者自我管理干预的系统评价

来源：综述 | 年份：2020 | 类型：review

摘要片段占位：系统评价纳入了多项随机对照研究，结果表明自我管理干预可改善 COPD 患者生活质量，减少急性加重风险……

⋮ 还有 3 条候选结果

备用：预存候选 JSON（网络/环境失败时改用）

重点是数据结构不是安装速度

# 03

## RAG 衍生：混合检索、重排与互补证据

要互补的证据包，不是重复的检索结果



# BM25 精确抓药名和编号，但漏同义改写



**擅长：精确药名、PMID、NCT、缩写**

例：某药 20mg / NCT01234567

能精准命中具体药名、剂量、研究编号和缩写等精确匹配的信息。



**盲区：同义改写、口语表达**

对改写表达、近义替换、口语化表述等语义层面的查询，容易漏检或匹配不准。



**适合精确问题**

医学场景同时有“限钠是否有用”这种语义问题，也有“某药某剂量/某 NCT”这种精确问题，BM25 正好匹配后者。

# 向量检索懂改写问法，但漏精确编号

向量检索擅长概念相近、问法改写这类语义相似匹配，但常见盲区是精确术语、数字与编号；医学场景同时有“限钠是否有用”这种语义问题，所以只做向量检索不是默认最专业的选择。



**擅长：概念相近、问法改写**

例：限钠饮食是否有用



**盲区：精确术语、数字与编号**



**只做向量检索不是默认最专业**



**先跑通一种，有余力再融合**

先让基础组跑通一种；有余力再做融合，避免因为技术堆叠而没有可用原型。

## 混合检索不是替换向量库，是加一条关键词分支




两路并行召回，互不替代

# RRF 按名次融合两路结果，k=60 是常用起点



赛道三可将“向量单路 vs 混合检索”作 Arm B 内部对照

# 先召回一批候选，重排只在候选里排序



cross-encoder: 一起读问题和候选，判断是否相关

✓ 合理：Top-20~50 召回 → 重排取 Top-5

# 没召回到，重排也没有魔法

不合理：cross-encoder 跑全库



没召回，重排没有魔法



先查召回，再查排序




进阶实验：Top-5 vs Top-20→rerank Top-5

同题比较“向量 Top-5”与“向量 Top-20→rerank Top-5”的相关性与延迟

# 相关不等于互补，MMR 要问两件事

MMR 每选一篇都同时问“它和问题相关吗”与“它和已选文献重复吗”；好的证据包是一份近期指南+一篇系统综述+一项代表性 RCT，而不是三个同类综述——目标是互补的 7 篇，不是重复的 12 篇。



延伸说明：对赛道二，主题页也可承担去冗余：把多个原始片段先压缩成“证据分级+局限”，再交给 MMR 进行互补挑选。

# 先选证据、再定角色：这题该留哪三张？

🕒 思考 3 分钟

成人限钠干预，是否有高质量证据支持其降低血压？

**A**

**A 2002叙述性综述**

结论偏旧，未纳入近二十年 RCT

**B**

**B 2023系统综述**

汇总效应量与证据分级

**C**

**C DASH-Sodium RCT**

三级钠摄入，血压为主要结局

**D**

**D PURE观察性队列**

关联证据，存在混杂与测量误差

**E**

**E 钾盐替代品试验**

干预是换盐，对象为养老机构高龄者

留三张：总览 / 因果 / 边界



总览



因果



边界



不问哪篇最好，问回答需要哪类证据角色

# 示范组合：总览看图景，因果靠 RCT，边界写清局限

**总览 ← B 2023系统综述**

画出整体证据图景与证据等级

**不选 A：过时总览**

会被更新综述覆盖

**因果 ← C DASH-Sodium RCT**

直接支撑“限钠干预 → 血压变化”

**边界 ← D PURE观察性队列**

写清混杂、外推与真实世界关联限制

**不选 E：干预/人群不匹配**

相关但答错题

**回答要让证据各司其职**

检索+重排只能排序，角色结构仍需人工检查

# 04 幻觉第一层与第二层

引用存在，不代表引用支撑结论



# 假引用最容易查，也是最低限度必须防的一层

常见表现是编造作者、期刊、年份、PMID、DOI，或给真实 PMID 但内容与之无关；  
基础防线是不让模型自由生成参考文献列表，引用编号只能从检索结果的 source\_id 中选；  
赛道三要记录引用存在率。



## 伪造示例

- 编造作者/期刊/年份/PMID/DOI
- 给真实 PMID 但标题、结论与它无关

示例：给出真实 PMID：12345678，  
但标题或结论与该 PMID 的实际内容完全不符。



## 合规做法

- 不让模型自由生成参考文献列表
- [1] 必须映射到真实 pmid/doi/nct/chapter



## URL 是否能打开



记录：引用存在率

不止是有没有 [1] 这个符号，还要确认 [1] 映射的引用客观存在。

# 文献是真的，句子也顺，但证据没支撑这句话

这不是假引用，而是陈述支撑度不足；RAGAS faithfulness 的朴素做法是把回答拆成原子陈述逐句检查是否能从返回 chunk 推出；课堂手动版是圈出可核查事实句，划不出支持句就删、改弱或拒答。

## 检索片段只说



限钠与血压相关

## 回答却补出



限钠与血压相关，并且<sup>①</sup>精确效应量、  
<sup>②</sup>人群、<sup>③</sup>治疗建议  
可作为临床方案依据。

## 陈述支撑度不足




划不出支持句：删、改弱、拒答

删

改弱

拒答

# 四种情况必须触发拒答，不能硬答



# 合格拒答要说清楚：检索到什么、缺什么、下一步查什么



来自上一页阀门的“拒答”输出

合格拒答 = 已检索到什么 + 缺什么 + 建议补查什么

合格拒答不等于“~~我不能回答~~” ❌

“

现有知识库中未找到能直接支持这一结论的高质量证据。  
我能确认的是……；如需继续，应检索……类型的指南/RCT。

”



赛道二：拒绝诊疗 + 公开范围 + 就医提示

# 阈值先用四条可解释规则，不追最佳数字

三天项目不需要假装已经校准出医学级置信度模型；先把判断条件记录下来。

- 1 规则1：来源<3个 → 不下确定结论
- 2 规则2：缺预期证据类型 → 标注不足
- 3 规则3：证据冲突 → 并列呈现，不选边
- 4 规则4：问吃药/停药 → 安全拒答

赛道三把这些规则写入 config，统计拒答率与违规率的取舍。

# RAG 评估三条路：程序化、模型评判、人工评估

核心结论：程序化适合查引用映射、ID/URL、拒答规则等客观项；高级模型评判（含 RAGAS/LLM-as-judge）适合 faithfulness 与 rubric；人工评估适合边界、安全与证据角色；起步建议先程序化挡假引用，再人工抽查支撑度，进阶再加模型评判。



## 程序化

程序化：引用映射 / ID / URL / 拒答规则

客观、可批量



## 高级模型评判

高级模型评判：LLM-as-judge / RAGAS

适合忠实度与 rubric



## 人工评估

人工评估：题集 + 评分表 + 抽查

边界与安全不可替代

## 可单用，也可叠用

先程序化挡假引用，再人工抽查支撑度，进阶再加模型评判。

# 05

## LLM Wiki: 把高频知识编译成主题页

先编教材，再从教材里查





Post



Andrej Karpathy

@karpathy



## LLM Knowledge Bases

Something I'm finding very useful recently: using LLMs to build personal knowledge bases for various topics of research interest. In this way, a large fraction of my recent token throughput is going less into manipulating code, and more into manipulating knowledge (stored as markdown and images). The latest LLMs are quite good at it. So:

### Data ingest:

I index source documents (articles, papers, repos, datasets, images, etc.) into a raw/ directory, then I use an LLM to incrementally "compile" a wiki, which is just a collection of .md files in a directory structure. The wiki includes summaries of all the data in raw/, backlinks, and then it categorizes data into concepts, writes articles for them, and links them all. To convert web articles into .md files I like to use the Obsidian Web Clipper extension, and then I also use a hotkey to download all the related images to local so that my LLM can easily reference them.

# Wiki 不是另一个向量库，是提前把知识编译好

**RAG:** 每次提问都翻资料

**Wiki:** 先编教材，再从教材查



**Schema 规定字段/引用格式/更新流程**

# Ingest：新资料进来，先摘要再更新主题页

核心结论：新资料进入后要先摘要、更新相关主题页、加来源和链接、记日志——  
这是 LLM Wiki 维护闭环的入口动作，价值不在一次性生成百科，而在有明确的维护流程。

Ingest



价值不在一次性生成百科，而在有明确的维护流程——先摘要、再更新、加来源、记日志，形成可持续的维护闭环。

# Query: 先找主题页，综合后再回答，来源不丢

Query



Query 从 `index.md` 定位相关主题页，综合内容后作答，并保留来源引用；这与 RAG “每次提问都翻原始资料”不同，Wiki 已经把知识提前编好，查的是教材而不是原始资料堆。

与 RAG 的区别：这与 RAG “每次提问都翻原始资料”不同，Wiki 已经把知识提前编好，查的是教材而不是原始资料堆。

# Lint：定期检查失效链接、孤立页与过时结论

Lint 要找失效链接、孤立主题页、过时结论、来源冲突和缺失字段；

Ingest/Query/Lint 这套闭环很适合赛道二的稳定科普主题，也适合把指南条目化。

Lint



失效链接



孤立主题页



过时结论



来源冲突



缺失字段

适合赛道二稳定科普主题，也适合条目化指南

# 不追百科全书，一页有边界的高质量主题页就够

|        |                                                              |                                                                                     |
|--------|--------------------------------------------------------------|-------------------------------------------------------------------------------------|
| 主题     | 限钠与血压                                                        |  |
| 一句话结论  | 现有证据支持低钠饮食可小幅降低血压并减少心血管事件风险.....                             |                                                                                     |
| 适用范围   | 成人高血压或高血压风险人群的一般性饮食建议.....                                   |                                                                                     |
| 关键证据   | 多项随机对照试验与系统综述显示：降低每日钠摄入量可使收缩压下降约 2-5 mmHg，并降低卒中和冠心病事件风险..... |                                                                                     |
| 局限与争议  | 证据主要来自中等风险人群；对低血压、老年或合并疾病人群的长期影响仍需更多研究；个体差异与钠替代效应存在不确定性..... |                                                                                     |
| 不该回答什么 | 个体剂量、替代临床诊疗.....                                             |                                                                                     |
| 最后更新   | 日期/资料版本                                                      |                                                                                     |

# Wiki 管高频稳定知识，RAG 管长尾刚更新问题



适合 Wiki: 高频、结构稳定的主题解释



需要读者直接浏览的知识页

已人工审核过的综合结论



已人工审核过的综合结论

结构稳定、持续复用的主题解释



适合 RAG: 长尾、具体、刚更新的问题



需要回到原始文献的证据片段

尚未被整理的新资料



尚未被整理的新资料

长尾、具体、刚更新的问题



医学场景共同约束：都要保留 PMID/DOI/章节链接

回答界面可先展示主题页摘要，再展示补充原始文献。

# 持续维护不是可信度保证，错误会被引用放大



摘要



错误会被后续页面引用并放大



原始来源不可被  
覆盖或删除



每个结论保留来源  
和更新时间



矛盾要记录，不  
私自修正成唯一答案



规模上升后要加人工复核点；本项目只需对核心主题页做人工核查。

备用：一张结构化主题页即可计入进阶

# 06

## Prompt写作要点

规则比角色设定更重要



# RAG 的 Prompt 分三层，规则不能只交给用户

1



查询改写

尤其适合赛道二

把口语提问转检索词，尤其适合赛道二。

2



系统规则：依据范围/引用格式/拒答冲突

规定依据范围、引用格式、拒答与冲突行为。

3



答案组装：去重/排序/生成结构

规定多证据如何去重、排序、生成结构。

可合并写入  
一个 system prompt

用户只负责问题，系统负责证据纪律

## 四条不能妥协的规则，可以直接拷进项目

- 1 你只能依据下列证据片段作答，不能用训练知识补全。
- 2 每一条事实性陈述后必须紧跟证据编号，如 [1]。
- 3 没有任何编号能支撑的陈述，不得写入回答。
- 4 证据不足、冲突或问题超出范围时，要明确说明边界并拒绝猜测。



规则比角色设定更重要



引用只能来自本次  
检索到的证据包



禁止自由补  
参考文献列表

# 无论哪条赛道，证据纪律都不能打折

澄清一种常见误解：面向普通消费者并不意味着可以把不确定性藏起来。

面向普通消费者并不意味着可以把不确定性藏起来；赛道一和赛道二都必须  
仅基于证据、逐句引用、缺失即说明、冲突即呈现，差异只在解释方式，不在事实约束。

仅基于证据作答

逐句引用

缺失即说明

冲突即呈现

赛道一、赛道二共同遵守

# 赛道一讲指南和 RCT，赛道二讲“研究提示”

纪律相同，语言层不同



## 赛道一



用语

指南、RCT、结局、适用人群



输出

证据概览+来源



禁区

替代临床决策



## 赛道二



用语

“研究提示”、生活方式、局限



输出

通俗结论+边界+来源



禁区

个体化诊疗、用药剂量

免责声明放答案后，不能替代对问题本身的安全回应

# 引用不是书目，是每个判断的可追溯锚点

核心结论：引用不是长长的参考书目，而是回答中每个判断的可追溯锚点；

正文格式是陈述后紧跟 [1][2]，证据卡格式是标题 | 年份 | source\_type | PMID/DOI | 链接；

同一句用多来源时并列编号，不要为了显得“有依据”把无关文献堆上去。

限钠干预在部分研究与血压下降相关 [1][2]。

[1] 标题 | 年份 | source\_type | PMID/DOI | 链接

① 同一句多来源可并列，不堆无关文献


# 验证程序三步：解析编号、查映射表、查真实 ID



## 验证程序



解析 `[\d+]`



检查编号是否在  
evidence map 中



检查是否有真实 ID/URL



赛道三：保存生成编号与实际 map —— 保存“模型生成的每个编号”和“实际 evidence map”，以便统计假引用。

# 分歧、答不全、越界：三种诚实输出都合格

核心结论：有分歧时说明不一致及可能原因；只覆盖一部分时说清能答什么、不能答什么；  
问题越界时拒绝个体化建议，转一般证据与就医提示。三种输出都是合格结果，评分不奖励永远有答案。



## 有分歧：说明不一致及可能原因

研究对象/时间/证据级别



## 只覆盖一部分：说清能答什么、不能答什么

例句：以下只能回答 X，Y 尚无足够证据



## 问题越界：拒绝个体化，转一般证据+就医提示

不提供个体化建议，提供一般证据与就医提示



**三种输出都是合格结果**



**诚实比完整更重要**

评分不奖励永远有答案

# 07

## 本半天小结与实践启动

先稳住这条链，明天再让它变聪明



# 从资料到可信回答，中间有四道关

RAG、混合检索、重排、Wiki、Prompt 不是独立名词，而是在不同位置保证这条链不掉；  
系统最容易坏在中间两步——检索噪声和模型补全；明天会把这条链继续接到 Tool、Agent 和评估。



最容易坏在中间两步

# 三条主线，每组只选一条，不并行追逐

推荐

## 路线A：最小RAG（推荐全员起步）



- 实践期不允许并行追逐所有技术名词；从最小闭环开始，打通端到端链路。



## 路线B：RAG进阶（加一项即可）



- 在路线 A 稳定后，加入以下一项能力，提升召回质量或排序效果。

metadata  
过滤

BM25/  
RRF

rerank

三选一即可，不需要同时上全部。

## 路线C：LLM Wiki（赛道二优先）



- 完成一个有原始来源、局限与更新时间的主页，再用它回答一个问题。

原始来源

局限

更新时间



## 赛道三：Arm A + Arm B 都要保存

- 至少完成 A 的 Arm B，同时用同一问题、同一底座运行裸 LLM Arm A，保存两份原始输出。

# 推进建议：先闭环，卡住就降级

核心结论：实践期先守最小闭环；卡住立刻降级；有余力再扩容。不能牺牲证据链。



1 先守最小闭环：入库 → Top-K → 带引用回答



2 卡住就降级：小样例 / 关键词Top-3 / CLI



3 有余力再扩容：混合检索、重排、Wiki 三选一



不能牺牲证据链

约前 55 分钟守闭环，后半程再抽查与扩容

# 明天，把这条证据链拆开测

 先让系统知道何时不能说，再讨论它怎样说得更多

 带着测试题、原始输出、evidence map 进入 D2 上午



Tool/MCP 可以补查文献，Agent 可以动态换检索策略，

Tool/Agent 不能替代今天的证据纪律